

APRENDIZAJE DE MÁQUINA

Sumativa 1:

Sistema de recomendación de artistas con potencial de convocatoria para eventos musicales en Chile basado en rankings diarios de Spotify

Nombres integrantes: Diego Mulatti Morales, Alejandro Ortega Aranda, Omar Sanhueza Becar.

Índice

1. Problemática	4
1.1. Problemática y análisis de trabajos previos.	4
1.2. Requisitos iniciales del proyecto	5
a. Requisitos funcionales	6
i. Definición de señales digitales locales para el modelamiento	7
b. Requisitos no funcionales	8
2. Metodología	10
2.1. Análisis exploratorio de datos	10
2.2. Selección de técnicas de aprendizaje automático	10
2.3. Diseño de la arquitectura	10
2.4. Implementación, Validación y Evaluación	11
2.5. Plan de Trabajo	11
3. Desarrollo del proyecto	13
3.1. Análisis exploratorio de datos	13
3.1.1 Selección y preparación del conjunto de datos	13
3.1.2 Análisis exploratorio y patrones estadísticos	19
3.2. Selección y justificación de técnicas de modelamiento	24
3.2.1. Comparación de técnicas supervisadas y no supervisadas	24
3.2.2. Técnicas candidatas seleccionadas	26
iii. Red neuronal Perceptrón Multicapa (MLP)	26
3.2.3. Comparación de técnicas de Machine Learning y arquitecturas de Deep Learning	27
3.3. Preparación de la base agregada por artista	29
3.4. Selección de variables y escalamiento	30
3.5. Reducción de dimensionalidad con PCA.	31
3.6. Segmentación de artistas mediante K-Means.	32
3.7. Implementación del modelo supervisado MLP.	34
3.8. Comparación de estrategias de balanceo	36
3.9. Evaluación final del modelo seleccionado	36
3.10. Visualización de la matriz de confusión	37
3.11. Explicabilidad del modelo con SHAP	38
3.12. Revisión de casos particulares del conjunto de prueba	39
3.13. Diseño conceptual de frontend y backend	40
3.14. Limitaciones del modelo y mejoras futuras	43
4. Resultados y análisis del modelo	44

5. Repositorio GitHub y reproducibilidad	45
6. Conclusiones	46
Referencias.....	47

1. Problemática

1.1. Problemática y análisis de trabajos previos.

Las productoras y organizadores de eventos musicales deben seleccionar artistas para festivales, conciertos y eventos masivos en un contexto de alta incertidumbre comercial. La elección de un artista no solo depende de su fama global, sino también de su presencia en mercados locales, estabilidad en rankings, crecimiento reciente, cantidad de canciones exitosas, alcance regional y afinidad con el público objetivo. En Chile, eventos como festivales musicales, conciertos masivos o ciclos universitarios requieren tomar decisiones de programación que pueden implicar altos costos de producción; sin embargo, muchas veces estas decisiones se basan en criterios parciales, como percepción de popularidad, tendencias en redes sociales o reconocimiento general del artista. Esto puede llevar a seleccionar artistas con alta visibilidad internacional, pero que no necesariamente presentan una alta señal digital local asociada al potencial de convocatoria en el mercado chileno.

La revisión de trabajos previos muestra que el uso de datos de Spotify en proyectos de análisis musical y aprendizaje automático se ha abordado principalmente desde la predicción de popularidad de canciones, el éxito en rankings y los sistemas de recomendación musical. Cabansag y Ntegeka (2025) utilizaron rankings diarios de Spotify y variables de audio para predecir éxito en charts mediante modelos supervisados como Logistic Regression, KNN, Random Forest y XGBoost. Aunque corresponde a un preprint de arXiv, su aporte es útil como antecedente técnico, ya que demuestra que los rankings diarios pueden ser utilizados como base para modelar comportamiento musical. Sin embargo, su enfoque se centra en predecir el éxito de canciones dentro de rankings, no en construir perfiles de artistas para apoyar decisiones de programación de eventos.

Saragih (2023), por su parte, utilizó características musicales de Spotify para predecir popularidad de canciones en usuarios de streaming de Indonesia. Este trabajo permite observar que variables como danceability, energy, tempo o acousticness pueden aportar información útil para modelar popularidad musical. No obstante, su alcance sigue estando centrado en canciones individuales y no incorpora una comparación específica del desempeño de artistas en mercados locales. De manera similar, Jiang (2025) abordó la predicción de popularidad musical mediante técnicas de aprendizaje automático, reforzando que la popularidad puede modelarse con múltiples variables, aunque nuevamente desde una lógica de predicción de canciones y no desde perfiles de artistas.

Sebastian Jung y Mayer (2024) también analizaron la popularidad musical mediante aprendizaje automático. Este antecedente es útil porque refuerza la idea de que la popularidad no depende de una sola característica, sino de una combinación de factores. Sin embargo, debe considerarse que este trabajo corresponde a un preprint de arXiv, por lo que no tiene el mismo nivel de validación académica que un artículo publicado en una revista revisada por pares. Aun así, se utiliza como referencia complementaria para situar el problema, no como fuente principal de validación metodológica.

El antecedente más cercano a esta propuesta es el trabajo de Sudipa, Sugiartawan y Wiguna (2022), quienes desarrollaron un sistema de apoyo a la decisión para seleccionar artistas en un festival musical utilizando criterios como seguidores, popularidad, canciones populares, visualizaciones en YouTube y costo del artista. Este trabajo es relevante porque sí se aproxima al problema de seleccionar artistas para eventos. Sin embargo, se basa en métodos multicriterio y en una muestra reducida, sin utilizar rankings diarios por país ni técnicas de aprendizaje automático no supervisado para construir perfiles de artistas. Por lo tanto, deja

abierto un espacio para una propuesta basada en datos masivos de consumo musical y segmentación de artistas según señales digitales observables.

Finalmente, Terroso-Saenz et al. (2023), publicado en Pattern Recognition, muestra que la música presenta patrones de propagación entre países, lo que respalda la necesidad de considerar el desempeño local de los artistas y no solo su popularidad global. Este antecedente es especialmente importante para el proyecto, ya que permite justificar el análisis de rankings diarios como una fuente útil para observar patrones de consumo musical. Por otra parte, Turnbull et al. (2022) advierten sobre el sesgo de popularidad en sistemas de recomendación musical. Si bien este último trabajo también corresponde a un preprint de arXiv, su aporte es útil para recordar que un sistema de recomendación no debería limitarse a reproducir la fama global de los artistas, sino incorporar criterios explicables que permitan considerar artistas regionales, emergentes o de nicho.

En este contexto, el proyecto propone desarrollar un sistema de apoyo a la decisión que permita identificar perfiles de artistas a partir de rankings diarios de Spotify Chile. El objetivo no es asegurar ventas de entradas ni predecir con certeza la asistencia a un evento, sino estimar señales digitales locales asociadas al desempeño de los artistas en el mercado chileno. De esta manera, el proyecto se diferencia de los trabajos previos al trasladar el foco desde la predicción de popularidad de canciones hacia la identificación de perfiles de artistas que puedan apoyar decisiones de programación musical y lineup en eventos musicales en Chile.

1.2. Requisitos iniciales del proyecto

A partir del análisis de la problemática y de los trabajos previos revisados, se definieron requisitos iniciales para orientar el desarrollo del sistema. Estos requisitos buscan asegurar que el proyecto pueda procesar rankings diarios de Spotify, transformar la información desde el nivel de canción hacia el nivel de artista, construir métricas agregadas de desempeño local y presentar resultados interpretables para usuarios no técnicos, como productoras, equipos de marketing u organizadores de eventos.

El sistema no busca predecir de manera directa la convocatoria real de un artista, ya que el dataset no contiene datos de venta de entradas, asistencia a eventos ni recintos. Por lo tanto, los requisitos se orientan a construir una herramienta de apoyo basada en señales digitales locales observadas en Spotify Chile. Finalmente, el sistema debe presentar resultados comprensibles mediante tablas, gráficos, métricas de evaluación y herramientas de explicabilidad. Esto incluye comparar estrategias de balanceo, evaluar el modelo con datos no observados, visualizar la matriz de confusión, interpretar la importancia de variables mediante SHAP y proponer una interfaz conceptual de frontend/backend. Estos requisitos buscan que el proyecto no solo entregue un modelo predictivo, sino también una herramienta interpretable y útil para apoyar decisiones de programación musical, manteniendo siempre la decisiones de programación musical, manteniendo siempre la cautela de que los resultados corresponden a señales digitales locales y no a una medición directa de convocatoria real.

a. Requisitos funcionales

Código	Requisito funcional	Relación con la problemática
RF1	El sistema debe permitir cargar y procesar el dataset de rankings diarios de Spotify.	Es necesario trabajar con datos reales de consumo musical para apoyar decisiones de programación.
RF2	El sistema debe filtrar los datos por país, fecha, artista y canción.	Permite analizar el comportamiento de artistas en Chile, Latinoamérica y el ranking global.
RF3	El sistema debe transformar los datos desde el nivel de canción hacia el nivel de artista.	La problemática se centra en seleccionar artistas para eventos, no canciones individuales.
RF4	El sistema debe calcular métricas agregadas por artista, como apariciones en ranking, mejor posición alcanzada, posición promedio, permanencia en ranking, cantidad de canciones rankeadas y presencia en distintos países.	Estas métricas permiten estimar señales de popularidad, estabilidad y alcance geográfico.
RF5	El sistema debe identificar perfiles de artistas según su comportamiento en rankings de Spotify.	Permite distinguir artistas globales, regionales, emergentes, virales o de nicho.
RF6	El sistema debe calcular un Índice de Potencial de Convocatoria musical por artista, compuesto por variables normalizadas de presencia en Chile, permanencia en rankings, posición alcanzada, diversidad de repertorio, alcance regional/global y tendencia reciente.	Permite transformar la problemática del proyecto en un criterio operativo para priorizar artistas. Este índice no busca asegurar ventas de entradas, sino entregar una señal comparativa y justificable para apoyar decisiones de programación musical en Chile.
RF7	El sistema debe permitir comparar artistas según desempeño en Chile, Latinoamérica y Global.	Evita basar la decisión solo en fama global o percepción subjetiva.
RF8	El sistema debe presentar resultados mediante tablas y visualizaciones simples.	Facilita que usuarios no técnicos puedan interpretar los perfiles y recomendaciones.
RF9	El sistema debe calcular la tendencia o tasa de crecimiento de un artista en un periodo determinado.	Permite diferenciar artistas en crecimiento reciente de artistas que mantienen altos números, pero con menor dinamismo en rankings.
RF10	El sistema debe manejar canciones con múltiples artistas, colaboraciones o featuring al transformar los datos desde canción hacia artista.	Permite asignar correctamente las canciones a los artistas involucrados, evitando duplicidades, pérdidas de información o una medición incorrecta del desempeño de cada artista.

i. Definición de señales digitales locales para el modelamiento

Para que el requisito RF6 sea aplicable dentro del proyecto, se define inicialmente el Índice de Potencial de Convocatoria (IPC) como una métrica compuesta que busca ordenar artistas según señales observables de consumo musical en Spotify. Este índice no representa ventas reales de entradas ni asegura asistencia a un evento, sino que entrega una aproximación comparativa basada en el desempeño del artista en rankings diarios.

El IPC se calculará a nivel de artista, luego de transformar los datos desde el nivel original de canción hacia una base agregada por artista. Para evitar que una sola variable domine el resultado, cada componente será normalizado en una escala común entre 0 y 1. De forma inicial, se propone la siguiente fórmula:

$$\text{IPC} = 0,25 * (\text{Presencia Chile}) + 0,20 * (\text{Permanencia}) + 0,15 * (\text{Posición local}) + 0,15 * (\text{Diversidad de repertorio}) + 0,15 * (\text{Alcance regional/global}) + 0,10 * (\text{Tendencia reciente})$$

Los componentes del índice se entienden de la siguiente manera:

- **Presencia Chile:** cantidad de apariciones del artista en rankings diarios de Spotify Chile durante el periodo analizado.
- **Permanencia:** cantidad de días o semanas en que el artista se mantiene dentro del ranking, lo que permite diferenciar artistas estables de apariciones puntuales.
- **Posición local:** desempeño del artista dentro del ranking chileno, considerando su mejor posición alcanzada y/o su posición promedio. Como en Spotify una posición menor indica mejor desempeño, esta variable deberá invertirse para que mejores posiciones entreguen mayor puntaje.
- **Diversidad de repertorio:** cantidad de canciones únicas del artista presentes en el ranking chileno. Este componente es importante porque un artista con muchas apariciones, pero explicadas por una sola canción, podría representar un fenómeno más puntual o viral. Por ello, esta dimensión también permitirá observar la dependencia de un solo hit.
- **Alcance regional/global:** presencia del artista en otros países latinoamericanos y en la referencia global del dataset. Esto permite distinguir artistas fuertes solo en Chile de artistas con proyección regional o internacional.
- **Tendencia reciente:** variación del desempeño del artista en el tiempo, considerando si su presencia en rankings aumenta, disminuye o se mantiene durante el periodo analizado.

Con esta definición, el índice queda más claro y justificable, porque cada componente responde a una necesidad del proyecto: evaluar presencia local, estabilidad, repertorio, alcance y crecimiento. Además, el índice podrá ajustarse en etapas posteriores según los resultados del análisis exploratorio y la retroalimentación recibida. Su objetivo principal no es predecir ventas de entradas, sino servir como apoyo para interpretar y comparar perfiles de artistas.

b. Requisitos no funcionales

Código	Tipo	Requisito no funcional	Vínculo con el Alcance y Antecedentes
RNF1	Usabilidad	El sistema debe presentar una interfaz clara, con filtros simples y visualizaciones comprensibles para usuarios no técnicos.	Se vincula con el contexto organizacional del proyecto, ya que los usuarios esperados serían productoras, equipos de marketing o encargados de programación musical, quienes necesitan interpretar resultados sin conocimientos avanzados en ciencia de datos.
RNF2	Explicabilidad	El sistema debe mostrar qué variables influyen en el perfil o recomendación asignada a cada artista.	Responde directamente a la advertencia de Turnbull et al. (2022) sobre el sesgo de popularidad en sistemas de recomendación musical, permitiendo justificar el valor de artistas emergentes, regionales o de nicho y no solo de artistas globalmente famosos.
RNF3	Escalabilidad	El sistema debe ser capaz de procesar el dataset original de rankings diarios y transformarlo en una base agregada por artista antes del modelamiento.	Se vincula con el volumen inicial del dataset de Asaniczka, que supera los dos millones de registros. Sin embargo, la escalabilidad no se entiende como entrenar modelos directamente sobre todos esos registros, sino como la capacidad de limpiar, filtrar y agregar los datos para construir una matriz final por artista, de menor tamaño y más adecuada para aplicar PCA, K-Means u otras técnicas de modelado.
RNF4	Seguridad	El sistema debe trabajar únicamente con datos públicos de artistas y canciones, sin almacenar información personal de usuarios.	El alcance del proyecto se limita a rankings musicales y características públicas de canciones, por lo que no requiere datos personales ni información privada de oyentes, compradores o asistentes a eventos.
RNF5	Confiabilidad	Los resultados deben ser reproducibles al utilizar el mismo periodo de análisis, filtros y criterios de cálculo.	Como el proyecto busca apoyar decisiones de programación musical, los perfiles de artistas deben generarse bajo criterios claros y repetibles, evitando recomendaciones arbitrarias o basadas solo en percepción subjetiva.
RNF6	Monitoreabilidad	El sistema debe permitir actualizar las métricas cuando se	Se relaciona con la naturaleza cambiante de la popularidad musical. Los rankings diarios permiten observar tendencias

		incorporen nuevos rankings diarios de Spotify.	recientes, por lo que el sistema debe poder monitorear cambios en el desempeño de los artistas a lo largo del tiempo.
RNF7	Rendimiento	El sistema debe optimizar el procesamiento mediante limpieza de datos, reducción de columnas no utilizadas, filtros geográficos y cálculo previo de métricas agregadas por artista.	Este requisito nace de la necesidad de evitar procesamientos innecesarios sobre la base completa en cada etapa. Una vez construida la tabla agregada por artista, los modelos trabajarán sobre un conjunto de datos más compacto, lo que permite reducir tiempos de ejecución y facilitar el análisis exploratorio, la visualización y el modelamiento.
RNF8	Mantenibilidad	El sistema debe estar estructurado de manera modular, separando las etapas de carga de los datos, transformación, cálculo de métricas y modelamiento, permitiendo la actualización de métricas o criterios, sin rehacer toda la estructura.	Los criterios que componen las características de los artistas pueden modificarse durante el proceso de creación del software. Por lo que es necesario que la lógica del sistema pueda modificarse de forma aislada, sin comprometer la estabilidad del proyecto.

Estos requisitos permiten vincular la problemática con el desarrollo técnico del sistema. En conjunto, orientan la construcción de una solución basada en aprendizaje automático que sea interpretable, reproducible y útil como apoyo exploratorio para la toma de decisiones en eventos musicales.

2. Metodología

2.1. Análisis exploratorio de datos

Se trabajó con el dataset “Top Spotify Songs in 73 Countries”, específicamente el archivo `universal_top_spotify_songs.csv`, recuperado desde Kaggle. Este conjunto de datos reúne rankings diarios de Spotify por país, incluyendo información sobre canciones, artistas, posición en rankings, fecha, popularidad y variables musicales.

Para enfocar el análisis en el mercado chileno, se filtraron los registros correspondientes a Chile. Tras este proceso se identificaron 29.105 registros iniciales, 540 canciones únicas y 408 valores únicos en la columna `artists`. Posteriormente, se evaluó la pertinencia del dataset, la completitud de los datos, la consistencia de las variables, la presencia de valores atípicos y la necesidad de aplicar medidas de depuración. El objetivo de esta etapa fue transformar progresivamente la unidad de análisis desde canciones presentes en rankings diarios hacia una base agregada por artista.

2.2. Selección de técnicas de aprendizaje automático

Dado que el dataset inicial no contiene una etiqueta real de convocatoria, venta de entradas o asistencia a eventos, el proyecto priorizó inicialmente técnicas de aprendizaje no supervisado para identificar perfiles de artistas a partir de señales digitales observables en Spotify Chile.

En esta etapa se seleccionaron PCA y K-Means como técnicas principales. PCA se utilizó para reducir la dimensionalidad de las variables y facilitar la representación de los artistas en un espacio de menor complejidad. K-Means permitió segmentar a los artistas en clusters según sus patrones de comportamiento en los rankings diarios de Spotify Chile.

Posteriormente, a partir de los clusters obtenidos, se construyó una etiqueta técnica binaria asociada a menor o mayor señal digital local. Esta etiqueta no representa convocatoria real, sino una clasificación derivada del comportamiento observado en Spotify. Con esta variable objetivo se incorporó una técnica supervisada de Deep Learning, específicamente una red neuronal de tipo Perceptrón Multicapa, orientada a clasificar artistas según su perfil de desempeño local.

Además, para mejorar la interpretación del modelo, se incorporó SHAP como herramienta de explicabilidad. Esta técnica permite analizar qué variables influyen con mayor fuerza en las predicciones del modelo, aportando transparencia al proceso de clasificación.

2.3. Diseño de la arquitectura

Para la fase supervisada se diseñó una arquitectura de red neuronal de tipo Perceptrón Multicapa, orientada a clasificar a los artistas en dos categorías técnicas: menor señal digital local y mayor señal digital local en Spotify Chile.

La arquitectura se definió utilizando la base agregada por artista, construida a partir del subconjunto chileno del dataset. El modelo trabajó con ocho variables predictoras: apariciones en Chile, canciones únicas en Chile, ranking promedio en Chile, popularidad promedio, movimiento diario promedio, movimiento semanal promedio, permanencia en días y puntaje de posición en Chile.

Se priorizó una arquitectura simple y controlada, adecuada para el tamaño del dataset disponible. La red neuronal incluyó capas densas, funciones de activación ReLU, una capa de regularización Dropout y una capa de salida sigmoide para abordar el problema como

clasificación binaria. Esta estructura permitió modelar relaciones no lineales sin aumentar innecesariamente la complejidad del modelo.

2.4. Implementación, Validación y Evaluación

La implementación consideró la reagrupación de los clusters obtenidos en dos clases técnicas, la partición del conjunto de datos en entrenamiento, validación y prueba, la estandarización de variables mediante StandardScaler y la aplicación de estrategias para enfrentar el desbalance de clases.

El conjunto de datos se dividió en tres subconjuntos: entrenamiento, validación y prueba. El conjunto de entrenamiento se utilizó para ajustar los pesos del modelo, el conjunto de validación permitió comparar configuraciones y estrategias de balanceo, y el conjunto de prueba se reservó exclusivamente para la evaluación final del modelo seleccionado.

Para abordar el desbalance de clases, se compararon cuatro escenarios: modelo sin balanceo, modelo con ponderación de clases, modelo con sobremuestreo y modelo con submuestreo. Esta comparación permitió seleccionar la estrategia más adecuada según métricas de desempeño como Accuracy, Precision, Recall, F1-score y AUC.

Finalmente, el modelo seleccionado fue evaluado sobre datos no observados del conjunto de prueba. La evaluación incluyó métricas de clasificación, matriz de confusión, análisis de casos particulares y explicación de variables mediante SHAP. Esto permitió analizar no solo el rendimiento predictivo, sino también la coherencia e interpretabilidad de los resultados obtenidos.

2.5. Plan de Trabajo

Para el desarrollo del proyecto, el grupo organizó el trabajo según los hitos definidos en el calendario del ramo. La planificación consideró tareas principales, responsables, horas estimadas, plazos concretos y vínculo con los requisitos del sistema. Además, se distinguió entre la construcción inicial del modelo, la depuración de datos, el análisis exploratorio, la implementación de técnicas de aprendizaje automático, la propuesta conceptual de frontend/backend y la consolidación del informe final.

Tabla 1. Plan de trabajo del proyecto.

Plazo / hito	Actividades principales	Responsabl e(s)	Horas estimadas	Requisitos asociados
Hasta el 28 de julio de 2026 — Sumativa 1: Informe segunda fase	Ajustar problemática y antecedentes, mejorar análisis crítico de literatura, corregir requisitos, definir el enfoque metodológico del proyecto, resolver la circularidad metodológica del uso de etiquetas construidas, incorporar análisis exploratorio inicial, técnicas candidatas, enlace a GitHub y mockup preliminar de la interfaz.	Diego Mulatti, Alejandro Ortega y Omar Sanhueza	8 h por integrante	RF1, RF2, RF5, RF6, RF8, RNF1, RNF2, RNF5
29 de julio al 11 de agosto de 2026 — Preparación para tercera fase	Profundizar limpieza de datos, revisar valores nulos, consistencia, outliers, fechas, registros incompletos y criterios para manejar colaboraciones. Transformar los datos desde canción hacia artista y construir variables agregadas.	Alejandro Ortega y Omar Sanhueza	8 h por integrante	RF1, RF2, RF3, RF4, RF10, RNF3, RNF7
Hasta el 18 de agosto de 2026 — Sumativa 2: Informe tercera fase	Construir la base agregada por artista, aplicar análisis exploratorio completo y ejecutar técnicas de modelamiento como PCA y K-Means. Interpretar resultados mediante gráficos, tablas y métricas de clustering.	Diego Mulatti, Alejandro Ortega y Omar Sanhueza	8 h por integrante	RF4, RF5, RF6, RF7, RF8, RNF2, RNF5
19 de agosto al 1 de septiembre de 2026 — Avance cuarta fase	Evaluar perfiles obtenidos, caracterizar clusters con estadísticos descriptivos, construir una etiqueta técnica, implementar una red neuronal MLP y refinar la propuesta de frontend/backend a partir del mockup inicial.	Diego Mulatti, Alejandro Ortega y Omar Sanhueza	6 h por integrante	RF1, RF2, RF5, RF8, RNF1, RNF2, RNF3, RNF8
Hasta el 8 de septiembre de 2026 — Sumativa 3: Entrega del proyecto, reporte técnico y de proceso	Consolidar el sistema propuesto, análisis de resultados, código en GitHub, README, explicación de perfiles, balanceo de clases, SHAP, limitaciones, formato APA, numeración de tablas y figuras, y coherencia final del informe.	Diego Mulatti, Alejandro Ortega y Omar Sanhueza	8 h por integrante	Todos los RF/RNF
Hasta el 15 de septiembre de 2026 — Sumativa 4: Examen final grupal	Preparar la defensa grupal del proyecto, presentando problemática, metodología, técnicas aplicadas, resultados, limitaciones, propuesta de frontend/backend y mejoras futuras.	Diego Mulatti, Alejandro Ortega y Omar Sanhueza	4 h por integrante	RF5, RF6, RF8, RNF2, RNF5

En resumen, la metodología busca avanzar de forma ordenada desde la definición del problema hasta la construcción de un sistema de apoyo a la decisión basado en señales digitales de Spotify Chile. El proyecto considera un backend para procesar y modelar los datos, y un frontend conceptual para mostrar resultados de forma clara. Además, contempla aspectos de usabilidad, escalabilidad, explicabilidad y monitoreo, de acuerdo con los requisitos definidos para el sistema.

3. Desarrollo del proyecto

3.1. Análisis exploratorio de datos

3.1.1 Selección y preparación del conjunto de datos

Para el proyecto se utilizó el dataset Top Spotify Songs in 73 Countries (Daily Updated), específicamente el archivo `universal_top_spotify_songs.csv`. Este dataset fue seleccionado porque permite analizar rankings diarios de Spotify por país, incluyendo Chile, lo que se relaciona directamente con la problemática del proyecto: identificar perfiles de artistas con potencial de convocatoria para eventos musicales en Chile.

En una primera revisión, el dataset presenta 2.110.316 registros y 25 columnas, con variables asociadas a canciones, artistas, posición en ranking, país, fecha, popularidad y características musicales. La unidad original de análisis corresponde a canciones presentes en rankings diarios, pero el proyecto busca transformar posteriormente estos registros hacia una unidad de análisis centrada en artistas.

<https://www.kaggle.com/datasets/asaniczka/top-spotify-songs-in-73-countries-daily-updated>

Característica	Resultado
Archivo analizado	<code>universal_top_spotify_songs.csv</code>
Total de registros	2.110.316
Total de columnas	25
Memoria utilizada	388,4 MB
Variables tipo texto	7
Variables numéricas enteras	8
Variables numéricas decimales	9
Variable booleana	1
Ranking diario disponible	Posiciones 1 a 50
Popularidad	Escala 0 a 100
Unidad original de análisis	Canción en ranking diario
Unidad esperada para el proyecto	Artista

El análisis inicial muestra que el dataset tiene un volumen alto de registros, lo que justifica la necesidad de aplicar filtros por país, fecha y artista antes del modelamiento. Además, contiene variables suficientes para construir métricas de desempeño musical, como permanencia en ranking, mejor posición alcanzada, popularidad promedio, movimiento diario/semanal y presencia por país. También se observan posibles valores que deberán revisarse en la etapa de limpieza, como canciones con duración igual a cero, tempo igual a cero o valores extremos en duración, ya que podrían corresponder a errores o registros atípicos.

a. Pertinencia del dataset para el caso de Chile

Como el proyecto busca identificar perfiles de artistas con potencial de convocatoria para eventos musicales en Chile, se verificó que el dataset incluyera registros asociados al mercado chileno. Para esto se filtró la variable country utilizando el código CL, correspondiente a Chile. El resultado muestra que existen 29.105 registros para Chile, con información entre el 18 de octubre de 2023 y el 11 de junio de 2025. Además, dentro de este subconjunto se identificaron 540 canciones únicas y 408 valores únicos en la columna artists.



```
chile = df[df["country"] == "CL"]

print("Registros de Chile:", chile.shape)
print("Rango de fechas Chile:", chile["snapshot_date"].min(), "a", chile["snapshot_date"].max())
print("Canciones únicas en Chile:", chile["name"].nunique())
print("Artistas únicos en Chile:", chile["artists"].nunique())
```

[0] ✓ 0.5s Python

... Registros de Chile: (29105, 25)
Rango de fechas Chile: 2023-10-18 a 2025-06-11
Canciones únicas en Chile: 540
Artistas únicos en Chile: 408

Figura 1. Filtrado del dataset para registros correspondientes a Chile (CL).

Este resultado confirma que el dataset permite analizar el comportamiento de canciones y artistas en el mercado chileno, lo que se relaciona directamente con el objetivo del proyecto. Sin embargo, se debe considerar que la columna artists puede contener colaboraciones o múltiples artistas en una misma canción, por lo que en etapas posteriores será necesario definir un criterio de limpieza para transformar correctamente los datos desde el nivel de canción hacia el nivel de artista.

b. Calidad de los datos

i. Análisis de completitud inicial

Para evaluar la completitud del dataset, se revisó la presencia de valores nulos en las columnas principales. En esta primera revisión se identificó que la variable country contiene 28.908 registros con valor nulo, lo que representa aproximadamente 1,37% del total de registros. Esta variable es importante para el proyecto, ya que permite comparar el comportamiento de artistas en Chile, Latinoamérica y otros mercados.

En una primera lectura, estos registros podrían interpretarse como datos sin país informado. Sin embargo, al analizarlos con mayor detalle se observó que no corresponden a filas vacías o incompletas, ya que mantienen canciones, artistas, fechas y posiciones válidas dentro del ranking. Además, presentan un promedio cercano a 50 registros por fecha, lo que es compatible con la estructura de un ranking diario Top 50.

Por este motivo, estos registros no serán eliminados automáticamente. Una interpretación posible es que correspondan al ranking Global de Spotify, representado en el dataset con

valor nulo en la variable country. Dado que el proyecto busca comparar el desempeño de artistas en Chile, Latinoamérica y una referencia global, estos registros podrían ser útiles para el análisis si se tratan como una categoría separada denominada Global.

Como medida de depuración preliminar, se propone revisar estos registros antes del modelamiento y, si se confirma su comportamiento como ranking global, reemplazar los valores nulos de country por la categoría Global. En caso contrario, deberán mantenerse separados del análisis por país para no asignarlos incorrectamente a un mercado específico.

En el caso del análisis enfocado en Chile, esto no afecta directamente el subconjunto filtrado con el código CL, ya que dicho subconjunto contiene registros válidos para el país y permite continuar con el alcance definido del proyecto.



```
print("Registros y columnas:", df.shape)
print("Cantidad de países:", df["country"].nunique())
print("Valores únicos en country:", len(df["country"].unique()))
print("Rango de fechas:", df["snapshot_date"].min(), "a", df["snapshot_date"].max())

missing_country = df["country"].isna().sum()
total = len(df)
print("Registros sin país:", missing_country)
print("Porcentaje sin país:", round(missing_country / total * 100, 2), "%")
```


✓ 0.6s Python

... Registros y columnas: (2110316, 25)
Cantidad de países: 72
Valores únicos en country: 73
Rango de fechas: 2023-10-18 a 2025-06-11
Registros sin país: 28908
Porcentaje sin país: 1.37 %

Figura 2. Revisión de registros con valor nulo en la variable country y análisis de su posible correspondencia con el ranking Global.

c. Análisis de consistencia

Para evaluar la consistencia del dataset, se revisó que las variables principales se encontraran dentro de los rangos esperados según su significado. En particular, se verificó que daily_rank estuviera entre 1 y 50, considerando que el dataset corresponde a rankings diarios Top 50. También se revisó que popularity estuviera entre 0 y 100, y que las características musicales como danceability, energy, speechiness, acousticness, instrumentalness, liveness y valence se mantuvieran dentro del rango 0 a 1. Además, se revisaron variables como key, mode, time_signature, duration_ms, tempo y snapshot_date.



```
... daily_rank fuera de 1 a 50: 0
daily_movement fuera de -49 a 49: 0
weekly_movement fuera de -49 a 49: 0
popularity fuera de 0 a 100: 0
danceability fuera de 0 a 1: 0
energy fuera de 0 a 1: 0
speechiness fuera de 0 a 1: 0
acousticness fuera de 0 a 1: 0
instrumentalness fuera de 0 a 1: 0
liveness fuera de 0 a 1: 0
valence fuera de 0 a 1: 0
key fuera de 0 a 11: 0
mode fuera de 0 a 1: 0
time_signature fuera de 1 a 5: 1
duration_ms igual a 0: 29
tempo igual a 0: 1
```

Figura 3. Revisión de consistencia de rangos en variables numéricas del dataset.

Los resultados muestran que la mayoría de las variables presenta una estructura consistente. No se identificaron valores fuera de rango en daily_rank, daily_movement,

weekly_movement, popularity, key, mode ni en las principales características musicales. Sin embargo, se detectaron algunos registros que deberán revisarse antes del modelamiento: 29 registros con duration_ms igual a 0, 1 registro con tempo igual a 0 y 1 registro con time_signature fuera del rango esperado. Estos casos representan una proporción muy baja respecto del total de datos, por lo que no invalidan el uso del dataset, pero sí deben considerarse dentro de la depuración.

```

Fechas inválidas en snapshot_date: 0
Fecha mínima: 2023-10-18 00:00:00
Fecha máxima: 2025-06-11 00:00:00

```

Figura 4. Revisión de consistencia de fechas en la variable snapshot_date.

En cuanto a la variable snapshot_date, no se identificaron fechas inválidas, ya que todos los registros pudieron convertirse correctamente a formato fecha. El rango temporal observado va desde el 18 de octubre de 2023 hasta el 11 de junio de 2025, lo que coincide con el periodo utilizado en el análisis inicial del dataset.

Como medida de depuración preliminar, se propone revisar los registros con duración igual a cero, tempo igual a cero y firma de tiempo fuera de rango. Si se confirma que corresponden a errores o valores no interpretables, estos registros serán excluidos de los análisis que utilicen características musicales, para evitar que afecten la construcción posterior de perfiles de artistas.

d. Análisis de valores atípicos

Para revisar la presencia de valores atípicos, se analizaron variables numéricas relevantes para el proyecto, especialmente duration_ms, tempo, loudness, popularity, daily_movement y weekly_movement. Estas variables pueden influir en la construcción posterior de perfiles de artistas, por lo que es importante identificar registros extremos antes de aplicar técnicas de aprendizaje automático.

	duration_ms	tempo	loudness	popularity	daily_movement	weekly_movement
count	2.110316e+06	2.110316e+06	2.110316e+06	2.110316e+06	2.110316e+06	2.110316e+06
mean	1.943095e+05	1.221008e+02	-6.772439e+00	7.590713e+01	9.230660e-01	2.932522e+00
std	4.986054e+04	2.781938e+01	3.874849e+00	1.576302e+01	7.015535e+00	1.233129e+01
min	0.000000e+00	0.000000e+00	-5.434100e+01	0.000000e+00	-4.900000e+01	-4.900000e+01
1%	1.058360e+05	7.199400e+01	-2.740500e+01	3.100000e+01	-1.400000e+01	-2.000000e+01
5%	1.308800e+05	8.197100e+01	-1.186000e+01	4.900000e+01	-7.000000e+00	-1.200000e+01
25%	1.626370e+05	1.000190e+02	-7.830000e+00	6.500000e+01	-1.000000e+00	-3.000000e+00
50%	1.861910e+05	1.199650e+02	-6.064000e+00	7.900000e+01	0.000000e+00	0.000000e+00
75%	2.187010e+05	1.400210e+02	-4.723000e+00	8.800000e+01	2.000000e+00	5.000000e+00
95%	2.763860e+05	1.737200e+02	-3.086000e+00	9.600000e+01	1.000000e+01	3.200000e+01
99%	3.547840e+05	1.920550e+02	-1.978000e+00	9.900000e+01	3.600000e+01	4.600000e+01
max	1.296000e+06	2.360890e+02	3.233000e+00	1.000000e+02	4.900000e+01	4.900000e+01

Figura 5. Estadísticas descriptivas de variables numéricas relevantes para detección de valores atípicos.

El resumen estadístico muestra que la mayoría de las variables se comporta dentro de rangos esperados. Por ejemplo, daily_movement y weekly_movement se mantienen entre -49 y 49,

lo que es coherente con un ranking Top 50. La variable popularity se mantiene entre 0 y 100. Sin embargo, se observan algunos valores que requieren revisión, como canciones con duration_ms igual a 0, un caso con tempo igual a 0 y canciones con duraciones muy superiores al promedio.

	name	artists	duration_ms	tempo	country	snapshot_date
502366	NaN	NaN	0	126.006	MA	2025-01-15
790671	NaN	NaN	0	113.032	IS	2024-10-17
1420334	NaN	NaN	0	120.046	TR	2024-04-27
1420357	NaN	NaN	0	140.081	TR	2024-04-27
1567150	NaN	NaN	0	98.071	UY	2024-03-14
1570595	NaN	NaN	0	98.071	AR	2024-03-14
1773300	NaN	NaN	0	140.007	IS	2024-01-18
1928350	NaN	NaN	0	118.024	ZA	2023-12-06
2022978	NaN	NaN	0	90.019	VE	2023-11-10
2023310	NaN	NaN	0	90.019	SV	2023-11-10
2023847	NaN	NaN	0	90.019	PE	2023-11-10
2023924	NaN	NaN	0	90.019	PA	2023-11-10
2024138	NaN	NaN	0	90.019	NI	2023-11-10
2025006	NaN	NaN	0	90.019	HN	2023-11-10
2025110	NaN	NaN	0	90.019	GT	2023-11-10
2025343	NaN	NaN	0	90.019	ES	2023-11-10
2025498	NaN	NaN	0	90.019	EC	2023-11-10
2025752	NaN	NaN	0	90.019	CR	2023-11-10
2025823	NaN	NaN	0	90.019	CO	2023-11-10
2025840	NaN	NaN	0	90.019	CL	2023-11-10

Figura 6. Registros con duración igual a cero.

En particular, los registros con duration_ms igual a 0 parecen corresponder a datos incompletos, ya que además presentan valores nulos en name y artists. Esto indica que no se trata solo de canciones muy cortas, sino de registros que no tienen información suficiente para ser utilizados en el análisis por canción o artista. Por esta razón, estos casos deberían ser eliminados antes del modelamiento o excluidos de las etapas donde se construyan métricas por artista.

	name	artists	duration_ms	tempo	country	snapshot_date
12405	Secessionini, Pt. 3	Neuf Voix	1296000	180.113	LU	2025-06-08
114446	bissu dumm ¿ MEGALODON REMIX	Bonez MC, Nate57, Jugglerz, AchtVier, AK 33, A...	1114155	94.964	DE	2025-05-11
136030	bissu dumm ¿ MEGALODON REMIX	Bonez MC, Nate57, Jugglerz, AchtVier, AK 33, A...	1114155	94.964	DE	2025-05-05
154722	bissu dumm ¿ MEGALODON REMIX	Bonez MC, Nate57, Jugglerz, AchtVier, AK 33, A...	1114155	94.908	AT	2025-04-30
168429	bissu dumm ¿ MEGALODON REMIX	Bonez MC, Nate57, AchtVier, AK 33, AK AUSSERKO...	1114155	94.908	DE	2025-04-18
169088	bissu dumm ¿ MEGALODON REMIX	Bonez MC, Nate57, AchtVier, AK 33, AK AUSSERKO...	1114155	94.908	AT	2025-04-18
118027	bissu dumm ¿ MEGALODON REMIX	Bonez MC, Nate57, Jugglerz, AchtVier, AK 33, A...	1114155	94.964	DE	2025-05-10
121628	bissu dumm ¿ MEGALODON REMIX	Bonez MC, Nate57, Jugglerz, AchtVier, AK 33, A...	1114155	94.964	DE	2025-05-09

Figura 7. Canciones con mayor duración registrada.

En el caso de las canciones con mayor duración, se observa que existen registros superiores a un millón de milisegundos, es decir, canciones de más de 16 minutos. A diferencia de los casos con duración cero, estos registros sí tienen nombre, artista, país y fecha, por lo que no necesariamente corresponden a errores. Podrían tratarse de versiones extendidas, remixes o piezas musicales largas. Por esto, se consideran valores atípicos válidos, pero deberán revisarse para decidir si se mantienen o si se limitan en los análisis basados en características musicales.

```
df[df["tempo"] == 0][["name", "artists", "duration_ms", "tempo", "country", "snapshot_date"]]
```

✓ 0.0s

	name	artists	duration_ms	tempo	country	snapshot_date
1827453	El Fua (La Luz)	Alfonso Vélez	203160	0.0	NI	2024-01-03

Figura 8. Registro con tempo igual a cero.

Finalmente, se identificó un registro con tempo igual a 0. En este caso, la canción sí presenta nombre, artista y duración válida, por lo que el problema parece estar asociado específicamente a la variable de tempo. Como medida preliminar, este valor deberá tratarse como dato no interpretable para análisis musicales basados en tempo, pudiendo ser excluido o reemplazado por un valor nulo antes del modelamiento.


En resumen, el análisis de valores atípicos muestra que el dataset es utilizable, pero requiere medidas de depuración puntuales: eliminar registros sin nombre ni artista con duración igual a cero, revisar el caso con tempo igual a cero y analizar si las canciones de duración extrema deben mantenerse como casos válidos o tratarse de forma separada.

e. Medidas de depuración preliminar

A partir del análisis de completitud, consistencia y valores atípicos, se aplicó una depuración inicial del dataset. Esta depuración fue conservadora, ya que no se eliminaron registros de forma masiva, sino únicamente aquellos casos claramente incompletos. En particular, se eliminaron los registros que presentaban `duration_ms` igual a cero y, al mismo tiempo, valores nulos en `name` y `artists`, ya que no era posible asociarlos a una canción ni a un artista específico.

Los registros con `country` nulo no fueron eliminados automáticamente, debido a que su estructura es compatible con un posible ranking global y podrían ser útiles para comparar el comportamiento de artistas frente a una referencia internacional. Por esta razón, se propone tratarlos como una categoría separada o mantenerlos bajo revisión antes del modelamiento. Además, los casos puntuales con tempo igual a cero o `time_signature` fuera del rango esperado fueron marcados como valores inconsistentes para evitar que afecten los análisis musicales posteriores.

Luego de aplicar la depuración inicial, el dataset pasó de 2.110.316 registros originales a 2.110.287 registros, eliminándose solamente 29 registros. Esto confirma que la calidad general del dataset es adecuada y que los problemas detectados son puntuales, por lo que el conjunto de datos sigue siendo pertinente para el desarrollo del proyecto.



```
Registros originales: 2110316  
Registros después de depuración: 2110287  
Registros eliminados: 29
```

Figura 9. Resultado de la depuración inicial del dataset.

3.1.2 Análisis exploratorio y patrones estadísticos

a. Caracterización general del dataset limpio

```
Registros del dataset limpio: 2110287  
Columnas: 26  
Rango de fechas: 2023-10-18 a 2025-06-11  
Países/categorías en country_clean: 73  
Canciones únicas: 21809  
Valores únicos en artists: 13726  
Registros de Chile: 29103  
Registros posibles Global: 28908
```

Figura 10. Caracterización general del dataset después de la depuración inicial.

Luego de la depuración inicial, el dataset mantiene 2.110.287 registros, 73 categorías en country_clean, 21.809 canciones únicas y 13.726 valores únicos en artists, por lo que conserva un volumen suficiente para análisis exploratorio y modelamiento.

b. Distribución geográfica de registros




Figura 11. Top 15 países/categorías con mayor cantidad de registros.

La distribución por país muestra cantidades muy similares entre las categorías con mayor presencia, alrededor de 29 mil registros. Esto es coherente con la estructura del dataset, ya que corresponde a rankings diarios Top 50 por país. Por lo tanto, esta visualización sirve para confirmar cobertura geográfica, más que para interpretar popularidad musical.

c. Artistas o combinaciones con más apariciones en Chile




Figura 12. Top 15 artistas o combinaciones con más apariciones en rankings de Chile.

En el caso de Chile, se observa que Cris MJ, Bad Bunny y KAROL G son los artistas o combinaciones con mayor presencia en rankings durante el periodo analizado. Esta variable no mide directamente venta de entradas, pero sí entrega una señal de permanencia y visibilidad local, útil para construir posteriormente perfiles de artistas.

Se debe considerar que la columna artists incluye tanto artistas individuales como colaboraciones, por lo que en etapas posteriores será necesario definir si las colaboraciones se mantienen como combinación o si se separan por artista individual.

Además, este análisis debe complementarse posteriormente con la cantidad de canciones únicas por artista, ya que un alto número de apariciones podría estar explicado por una sola canción muy exitosa. Esto es relevante para eventos musicales, porque un artista con presencia concentrada en un único hit puede no tener el mismo potencial de convocatoria o repertorio que otro artista con varias canciones posicionadas en rankings.

d. Cantidad de canciones únicas por artista en Chile




Figura 13. Top 15 artistas o combinaciones con más canciones únicas en Chile.

En este análisis se revisó la cantidad de canciones únicas asociadas a cada artista o combinación dentro del ranking chileno. A diferencia del gráfico anterior, que muestra la cantidad total de apariciones en el ranking, este resultado permite observar qué artistas tienen mayor diversidad de canciones posicionadas durante el periodo analizado.

Se observa que Bad Bunny presenta la mayor cantidad de canciones únicas en Chile, seguido por Cris MJ, Kidd Voodoo y KAROL G. Este resultado es relevante para el proyecto, ya que un artista con varias canciones rankeadas podría tener un repertorio más amplio y una presencia más sostenida, mientras que un artista con muchas apariciones concentradas en una sola canción podría corresponder a un fenómeno más puntual o viral.

Esta diferencia será importante para la construcción posterior de perfiles de artistas, ya que el potencial de convocatoria no debería depender únicamente de la cantidad total de apariciones en ranking, sino también de la diversidad del repertorio y de la estabilidad del artista en el tiempo. Además, se debe considerar que la columna artists incluye tanto artistas individuales como colaboraciones, por lo que esta variable deberá revisarse cuidadosamente antes de construir métricas definitivas a nivel de artista.

e. Distribución de popularidad en Chile




Figura 14. Distribución de popularidad de canciones en Chile.

El histograma muestra que la mayoría de las canciones presentes en el ranking chileno se concentra en valores altos de popularidad, principalmente entre 60 y 95 puntos aproximadamente. Esto es esperable, ya que el dataset corresponde a canciones que ya lograron ingresar a rankings diarios de Spotify, por lo que no representa canciones desconocidas o con baja circulación general.

También se observa una baja cantidad de registros con popularidad muy baja o cercana a cero. Estos casos no necesariamente invalidan el dataset, pero deberán considerarse en etapas posteriores, ya que podrían corresponder a canciones nuevas, registros con baja actualización de popularidad o valores poco representativos para el análisis de perfiles de artistas.

Esta distribución permite confirmar que la variable popularity puede ser útil como una señal complementaria, pero no debería ser el único criterio para estimar potencial de convocatoria, ya que el proyecto busca combinar popularidad con permanencia, presencia local, diversidad de canciones y comportamiento regional.

f. Relación entre variables numéricas




Figura 15. Mapa de calor de correlaciones en el subconjunto de Chile.

El mapa de calor permite observar relaciones entre variables numéricas del subconjunto chileno. Se identifican asociaciones esperables entre algunas características musicales, como energy, loudness, danceability y valence, mientras que otras variables presentan relaciones más débiles entre sí. También se observa que las variables de movimiento en ranking, como daily_movement y weekly_movement, tienen un comportamiento relacionado, pero no equivalente.

Este análisis es relevante porque muestra que el dataset contiene variables con distintos tipos de información: algunas describen el comportamiento de la canción en rankings, mientras que otras describen características musicales. Por esta razón, para etapas posteriores será necesario seleccionar variables, estandarizarlas y posiblemente reducir dimensionalidad antes de aplicar técnicas de agrupamiento.

En este contexto, el mapa de calor respalda la decisión de considerar técnicas como PCA y K-Means, ya que el proyecto requiere combinar múltiples variables para construir perfiles de artistas. PCA puede ayudar a resumir la información de variables relacionadas, mientras que K-Means permitiría agrupar artistas según patrones similares de desempeño.

3.2. Selección y justificación de técnicas de modelamiento

3.2.1. Comparación de técnicas supervisadas y no supervisadas

Para determinar el enfoque más adecuado para el proyecto, se compararon técnicas de aprendizaje supervisado y no supervisado según las características del dataset, la calidad de los datos disponibles y el objetivo principal del sistema. Esta comparación es importante porque el dataset utilizado contiene rankings diarios de Spotify, características musicales y variables de desempeño, pero no incluye una etiqueta real de venta de entradas, asistencia a eventos o convocatoria efectiva.

En este contexto, el aprendizaje no supervisado se consideró el enfoque inicial más adecuado, ya que permite identificar patrones y perfiles de artistas sin depender de una variable objetivo externa. Posteriormente, a partir de los clusters obtenidos mediante K-Means, se construyó una etiqueta técnica binaria para entrenar un modelo supervisado de clasificación. Esta etiqueta no representa convocatoria real, sino una clasificación derivada del desempeño digital observado en Spotify Chile.

Tabla 2. Comparación entre aprendizaje supervisado y no supervisado.

Criterio evaluado	Aprendizaje supervisado	Aprendizaje no supervisado
Requisito de datos	Requiere una variable objetivo previamente definida, por ejemplo, ventas de entradas, asistencia a conciertos o una etiqueta validada de convocatoria. El dataset no cuenta con esa información real.	Puede trabajar con datos sin etiqueta, identificando patrones y similitudes entre artistas a partir de variables observables del dataset.
Relación con el objetivo del proyecto	No es adecuado como enfoque inicial si se busca predecir convocatoria real, ya que obligaría a construir una etiqueta artificial sin validación externa.	Es adecuado como enfoque inicial, ya que permite descubrir perfiles de artistas según su comportamiento en rankings de Spotify Chile.
Riesgo metodológico	El principal riesgo es forzar una predicción sin contar con datos reales de convocatoria, lo que podría reforzar sesgos de popularidad o entregar conclusiones débiles.	Requiere interpretar cuidadosamente los grupos encontrados, pero evita asumir una variable objetivo inexistente.
Uso dentro del proyecto	Se utilizó posteriormente, pero no para predecir convocatoria real, sino para clasificar una etiqueta técnica derivada de los clusters.	Se utilizó como base metodológica inicial mediante PCA y K-Means para identificar perfiles de artistas.
Técnicas aplicadas	Red neuronal tipo Perceptrón Multicapa para clasificación binaria de la etiqueta técnica.	PCA para reducción de dimensionalidad y K-Means para segmentación de artistas.
Evaluación	Accuracy, Precision, Recall, F1-score, AUC y matriz de confusión sobre datos no observados.	Varianza explicada acumulada, Silhouette Score, Davies-Bouldin Index y Calinski-Harabasz Index.

A partir de esta comparación, el proyecto se orientó inicialmente hacia un enfoque no supervisado, ya que el objetivo no era predecir directamente si un artista venderá entradas, sino identificar perfiles de artistas a partir de señales observables de consumo digital, como presencia en Chile, permanencia en ranking, diversidad de repertorio, posición alcanzada, movimiento diario y semanal, popularidad promedio y puntaje de posición local.

Posteriormente, y con el fin de cumplir la etapa de clasificación supervisada, los clusters obtenidos se reagruparon en una etiqueta técnica binaria. Esta etiqueta permitió entrenar una red neuronal MLP para clasificar artistas según menor o mayor señal digital local en Spotify Chile. Por lo tanto, el enfoque final combina aprendizaje no supervisado para descubrir perfiles y aprendizaje supervisado para reproducir una clasificación técnica derivada de esos perfiles.

3.2.2. Técnicas candidatas seleccionadas

A partir de la comparación anterior, se seleccionaron cuatro componentes principales para el desarrollo del proyecto: PCA, K-Means, red neuronal MLP y SHAP. Estas técnicas fueron escogidas considerando la literatura revisada, la calidad del dataset, las restricciones computacionales y el objetivo central del proyecto, que es identificar perfiles de artistas a partir de rankings diarios de Spotify Chile y explicar los factores que influyen en la clasificación obtenida.

i. Análisis de Componentes Principales (PCA):

PCA se seleccionó como técnica de reducción de dimensionalidad, debido a que el proyecto trabaja con múltiples variables agregadas por artista. Estas variables incluyen apariciones en rankings de Chile, canciones únicas, ranking promedio, popularidad promedio, movimiento diario promedio, movimiento semanal promedio, permanencia en días y puntaje de posición local.

El uso de PCA permite resumir la información contenida en estas variables y representar a los artistas en un espacio de menor dimensión, conservando una proporción relevante de la variabilidad original. Esto facilita la visualización de patrones y prepara los datos para la etapa posterior de clustering.

Desde el punto de vista computacional, PCA resulta adecuado porque se aplica sobre una base agregada por artista y no sobre el dataset completo de más de dos millones de registros. Esto reduce el costo de procesamiento y mejora la interpretabilidad del análisis.

ii. K-Means Clustering

K-Means se seleccionó como técnica principal de agrupamiento no supervisado. Su objetivo fue segmentar a los artistas según patrones similares de desempeño digital en Spotify Chile. Esta técnica permitió identificar perfiles de artistas considerando variables como presencia en rankings, permanencia, diversidad de canciones, popularidad y posición alcanzada. La calidad de los grupos fue evaluada mediante métricas internas de clustering, como Silhouette Score, Davies-Bouldin Index y Calinski-Harabasz Index.

K-Means fue adecuado para esta etapa porque permite trabajar con datos sin etiqueta real de convocatoria. De esta forma, el proyecto evita asumir desde el inicio una clasificación externa inexistente y, en cambio, construye perfiles a partir de patrones observados en los datos.

iii. Red neuronal Perceptrón Multicapa (MLP)

Luego de obtener los clusters mediante K-Means, se construyó una etiqueta técnica binaria para clasificar artistas según menor o mayor señal digital local en Spotify Chile. A partir de esta etiqueta, se incorporó una red neuronal de tipo Perceptrón Multicapa como técnica supervisada de Deep Learning.

El MLP fue seleccionado porque permite modelar relaciones no lineales entre las variables agregadas por artista. La arquitectura utilizada incluye capas densas, función de activación ReLU, regularización mediante Dropout y una capa de salida sigmoide para clasificación binaria.

Es importante señalar que esta red neuronal no predice convocatoria real, venta de entradas ni asistencia a eventos. Su objetivo es aprender a reproducir una etiqueta técnica derivada de los perfiles obtenidos en la etapa no supervisada. Por ello, sus resultados deben interpretarse como una clasificación de señal digital local, no como una validación empírica de convocatoria.

iv. SHAP como herramienta de explicabilidad

Para interpretar el comportamiento del modelo supervisado, se incorporó SHAP (Lundberg y Lee, 2017) como herramienta de explicabilidad. Esta técnica permite analizar la contribución de cada variable en las predicciones del modelo, entregando una explicación más transparente del proceso de clasificación.

SHAP permite identificar qué variables influyen más en la probabilidad de que un artista sea clasificado como de mayor señal digital local. En este proyecto, su uso es relevante porque evita que el modelo funcione como una “caja negra” y permite justificar los resultados ante usuarios no técnicos, como productoras, equipos de marketing u organizadores de eventos. De esta manera, la explicabilidad del modelo no quedó centrada en Random Forest, sino en SHAP, que se aplicó directamente sobre el modelo MLP seleccionado.

En síntesis, PCA y K-Means se utilizaron para descubrir perfiles de artistas sin requerir una etiqueta real de convocatoria. Posteriormente, la red neuronal MLP permitió clasificar una etiqueta técnica construida a partir de esos perfiles, mientras que SHAP permitió interpretar qué variables influyeron más en las predicciones. Esta combinación mantiene la coherencia metodológica del proyecto y evita presentar los resultados como una medición directa de convocatoria real.

3.2.3. Comparación de técnicas de Machine Learning y arquitecturas de Deep Learning

Además de seleccionar las técnicas principales del proyecto, se realizó una comparación entre alternativas de Machine Learning y Deep Learning. Esta comparación permitió justificar por qué el flujo final se centró en PCA, K-Means y una red neuronal MLP, descartando arquitecturas más complejas que no se ajustaban al tamaño, estructura y objetivo del dataset.

Tabla 3. Comparación de técnicas de Machine Learning consideradas

Técnica ML	Tipo	Aplicabilidad al proyecto	Métricas o criterios de evaluación	Decisión
PCA	No supervisado	Reduce dimensionalidad de las variables agregadas por artista y facilita la visualización de patrones.	Varianza explicada acumulada.	Seleccionada. Permitió conservar aproximadamente el 91% de la varianza con cuatro componentes.
K-Means	No supervisado	Agrupar artistas según similitud en sus métricas de desempeño local en Spotify Chile.	Silhouette Score, Davies-Bouldin Index y Calinski-Harabasz Index.	Seleccionada. Permitió construir perfiles interpretables de artistas.
DBSCAN	No supervisado	Podría detectar artistas atípicos o fenómenos muy puntuales de aparición en rankings.	Cantidad de ruido, estabilidad de grupos y coherencia de outliers.	No seleccionada como técnica principal, porque el dataset agregado es pequeño y K-Means entregó perfiles más interpretables.
Random Forest	Supervisado	Podría usarse como modelo explicativo o comparativo posterior a la construcción de etiquetas técnicas.	Accuracy, precision, recall, F1-score, AUC e importancia de variables.	No seleccionado como modelo final, porque el proyecto priorizó una arquitectura neuronal MLP y explicabilidad mediante SHAP.

Tabla 4. Comparación de arquitecturas de Deep Learning consideradas.

Arquitectura DL	Aplicabilidad al proyecto	Calidad de datos requerida	Recursos computacionales	Decisión
Perceptrón Multicapa (MLP)	Permite clasificar artistas según una etiqueta técnica binaria derivada de los clusters.	Requiere una base numérica limpia, escalada y con variable objetivo definida.	Bajo a medio, adecuado para 408 artistas y 8 variables predictoras.	Seleccionada como arquitectura final.
RNN/LSTM	Podría modelar la evolución temporal diaria de los artistas en rankings.	Requiere transformar el dataset en secuencias por artista y fecha.	Medio a alto, con mayor complejidad de preparación y entrenamiento.	No seleccionada para esta fase, porque el proyecto trabaja con una base agregada por artista.
Transformer	Podría capturar patrones temporales complejos y relaciones entre países, artistas y rankings.	Requiere gran volumen de datos estructurados como secuencias y una formulación temporal avanzada.	Alto, con mayor costo computacional y mayor riesgo de sobreajuste.	No seleccionada, porque excede el alcance y recursos de esta etapa.

A partir de esta comparación, se definió que las técnicas más adecuadas para el proyecto eran PCA y K-Means en la etapa no supervisada, complementadas posteriormente con una red neuronal MLP para clasificación binaria. PCA permitió reducir la dimensionalidad, K-Means permitió construir perfiles de artistas y el MLP permitió aprender una etiqueta técnica derivada de dichos perfiles.

Las arquitecturas RNN/LSTM y Transformer fueron descartadas para esta fase porque requieren una reformulación temporal del problema y una mayor cantidad de datos secuenciales por artista. En cambio, el MLP resulta más adecuado para la base agregada construida en el proyecto, ya que trabaja directamente con variables numéricas resumidas por artista.

Esta decisión también responde a las restricciones computacionales del proyecto. La base final de modelamiento contiene 408 artistas o combinaciones de artistas y 8 variables predictoras, por lo que una arquitectura MLP simple permite modelar relaciones no lineales sin aumentar innecesariamente la complejidad del sistema.

3.3. Preparación de la base agregada por artista

Antes de aplicar las técnicas de modelamiento, se construyó una base agregada por artista a partir del subconjunto limpio de registros correspondientes a Chile. Esta transformación fue necesaria porque el dataset original se encuentra a nivel de canción en ranking diario, mientras que el objetivo del proyecto es identificar perfiles de artistas según señales digitales locales en Spotify Chile.

En esta etapa se trabajó con la columna artists tal como aparece en el dataset, por lo que las colaboraciones y canciones con múltiples artistas se mantuvieron como combinaciones. Esta decisión permitió conservar la estructura original de los rankings y evitar una separación artificial de colaboraciones que podría modificar la forma en que Spotify registra el desempeño de cada canción

A partir de los registros filtrados para Chile, se calcularon variables agregadas por artista, tales como cantidad de apariciones en rankings de Chile, cantidad de canciones únicas, ranking promedio, popularidad promedio, movimiento diario promedio, movimiento semanal promedio, permanencia en días y puntaje de posición local.

Como resultado, se obtuvo una base agregada compuesta por 408 artistas o combinaciones de artistas. Esta base permitió transformar el problema desde una lógica de canciones individuales hacia una matriz centrada en artistas, más adecuada para aplicar PCA, K-Means y posteriormente una red neuronal de clasificación binaria.

Tamaño de la base agregada por artista: (408, 13)

	artists	apariciones_chile	canciones_unicas_chile	mejor_rank_chile	peor_rank_chile	rank_promedio_chile	popularidad_promedio	movimiento_diario_promedio
61	Cris Mj	1808	14	1	50	20.824115	75.497235	0.440819
22	Bad Bunny	1233	22	1	50	18.789943	90.673966	0.356042
180	KAROL G	1071	9	1	50	30.783380	88.270775	0.267040
95	Feid, ATL Jacob	489	1	3	50	19.498978	90.411043	0.537832
367	Tiago PZK, Ke Personajes	399	1	5	49	19.546366	79.511278	0.508772
100	FloyyMenor, Lewis Somes	394	4	2	50	22.695431	74.682741	0.631980
98	FloyyMenor, Cris Mj	392	2	1	48	17.867347	83.471939	0.882653
190	Katleyes, Kidd Voodoo	370	2	1	50	20.000000	73.821622	0.416216
256	Lucky Brown, Mateo on the Beatz	357	2	1	50	19.529412	68.938375	1.025210
183	KAROL G, Peso Pluma	354	1	2	49	26.855932	89.644068	0.248588

Figura 16. Construcción de la base agregada por artista para el subconjunto de Chile.

3.4. Selección de variables y escalamiento

Luego de construir la base agregada por artista, se seleccionaron las variables numéricas que serían utilizadas en el modelamiento. Estas variables representan distintos aspectos del desempeño digital de cada artista o combinación de artistas en Spotify Chile, tales como presencia en rankings, diversidad de canciones, posición promedio, popularidad, movimiento en el ranking y permanencia.

Las variables seleccionadas para el modelo fueron: apariciones_chile, canciones_unicas_chile, rank_promedio_chile, popularidad_promedio, movimiento_diario_promedio, movimiento_semanal_promedio, permanencia_dias y puntaje_posicion_chile.

En esta etapa se decidió excluir variables identificadoras o de texto, como el nombre del artista, ya que no aportan valor numérico directo al proceso de modelamiento. Además, se mantuvo puntaje_posicion_chile como variable representativa del desempeño de posición, debido a que entrega una interpretación más directa: mientras mayor es el puntaje, mejor fue la posición alcanzada por el artista en el ranking chileno.

Antes de aplicar técnicas como PCA, K-Means y la red neuronal MLP, las variables fueron estandarizadas mediante StandardScaler. Esta transformación permite que todas las

variables queden en una escala comparable, evitando que aquellas con valores numéricos más altos dominen el análisis por sobre variables igualmente relevantes, pero con menor magnitud.

Como resultado, se obtuvo una matriz de modelamiento compuesta por 408 artistas o combinaciones de artistas y 8 variables numéricas escaladas. Esta matriz fue utilizada como base para las etapas posteriores de reducción de dimensionalidad, clustering y clasificación supervisada.

```

Valores nulos por variable:
apariciones_chile      0
canciones_unicas_chile 0
rank_promedio_chile    0
popularidad_promedio   0
movimiento_diario_promedio 0
movimiento_semanal_promedio 0
permanencia_dias       0
puntaje_posicion_chile 0
dtype: int64
Tamaño de la matriz escalada: (408, 8)

```

	artists	apariciones_chile	canciones_unicas_chile	rank_promedio_chile	popularidad_promedio	movimiento_diario_promedio	movimiento_semanal_promedio
61	Cris Mj	1808	14	20.824115	75.497235	0.440819	1.278761
22	Bad Bunny	1233	22	18.789943	90.673966	0.356042	2.223033
180	KAROL G	1071	9	30.783380	88.270775	0.267040	0.948646
95	Feid, ATL Jacob	489	1	19.498978	90.411043	0.537832	0.985685
367	Tiago PZK, Ke Personajes	399	1	19.546366	79.511278	0.508772	1.674185
100	FloyyMenor, Lewis Somes	394	4	22.695431	74.682741	0.631980	3.383249
98	FloyyMenor, Cris Mj	392	2	17.867347	83.471939	0.882653	2.645408
190	Kattheyes, Kidd Voodoo	370	2	20.000000	73.821622	0.416216	1.400000
256	Lucky Brown, Mateo on	357	2	19.529412	68.938375	1.025210	4.005602

Figura 17. Selección de variables y escalamiento para el modelamiento.

3.5. Reducción de dimensionalidad con PCA.

Posteriormente, se aplicó Análisis de Componentes Principales sobre la matriz escalada de variables por artista. Esta técnica fue utilizada con el objetivo de reducir la dimensionalidad de los datos, disminuir posibles redundancias entre variables y facilitar la visualización de patrones antes de aplicar el algoritmo de agrupamiento.

El uso de PCA fue pertinente porque las variables seleccionadas representan distintas dimensiones del desempeño digital de los artistas en Spotify Chile, pero algunas pueden estar relacionadas entre sí. Por ejemplo, un artista con muchas apariciones en el ranking también podría presentar mayor permanencia o una mejor posición promedio. Por ello, PCA permite resumir la información principal en un número menor de componentes.

Al aplicar PCA sobre las 8 variables numéricas escaladas, se observó que los primeros cuatro componentes principales explican aproximadamente el 91% de la varianza acumulada. Esto significa que fue posible conservar una proporción alta de la información original reduciendo la cantidad de dimensiones utilizadas para el análisis posterior.

Por esta razón, se decidió utilizar cuatro componentes principales como entrada para K-Means. Esta decisión permitió simplificar el proceso de agrupamiento, mejorar la eficiencia computacional y mantener una representación adecuada de los patrones presentes en los datos.




Figura 18. Varianza acumulada explicada por PCA sobre la matriz de artistas.

3.6. Segmentación de artistas mediante K-Means.

Una vez reducida la dimensionalidad mediante PCA, se aplicó K-Means con el objetivo de agrupar artistas o combinaciones de artistas según patrones similares de desempeño digital en Spotify Chile. Para esta etapa se utilizó la matriz compuesta por los cuatro primeros componentes principales, los cuales explicaban aproximadamente el 91% de la varianza acumulada.

Antes de seleccionar el número definitivo de clusters, se probaron distintos valores de k entre 2 y 8. La evaluación se realizó mediante tres métricas internas de clustering: Silhouette Score, Davies-Bouldin Index y Calinski-Harabasz Index. Estas métricas permiten analizar si los grupos formados son compactos, separados y coherentes desde el punto de vista estadístico. Los resultados mostraron que $k = 4$ obtuvo el mayor Silhouette Score, con un valor de 0,407501. Por otra parte, $k = 5$ obtuvo un Davies-Bouldin Index levemente menor y un Calinski-Harabasz Index mayor. Sin embargo, se seleccionó $k = 4$ porque entregaba la mejor separación promedio según Silhouette Score y permitía una interpretación más simple de los perfiles de artistas.




Figura 19. Evaluación del número de clusters para K-Means mediante métricas internas.

Posteriormente, se aplicó K-Means con cuatro clusters. Como resultado, los 408 artistas o combinaciones de artistas fueron distribuidos en cuatro grupos: 165 artistas en el cluster 0, 53 artistas en el cluster 1, 3 artistas en el cluster 2 y 187 artistas en el cluster 3.

```
Cantidad de artistas por cluster:
cluster
0      165
1       53
2        3
3      187
Name: count, dtype: int64
```

Figura 20. Cantidad de artistas por cluster luego de aplicar K-Means con k = 4.

Para interpretar los resultados, se analizaron las variables promedio de cada cluster. El cluster 2 se caracterizó por presentar el mayor número promedio de apariciones en rankings de Chile, mayor cantidad de canciones únicas, alta popularidad promedio y mayor permanencia en días. Este grupo incluyó artistas como Cris Mj, Bad Bunny y KAROL G, por lo que fue interpretado como un perfil de artistas consolidados de alto desempeño local.

El cluster 0 agrupó artistas con presencia sostenida en rankings chilenos, aunque con menor intensidad que el cluster 2. Este grupo presentó un promedio relevante de apariciones, buena popularidad y permanencia media, por lo que fue interpretado como un perfil de artistas con presencia estable o recurrente en el mercado chileno.

El cluster 1 reunió artistas con pocas apariciones y baja permanencia promedio, aunque con posiciones promedio no necesariamente bajas. Esto sugiere un perfil de aparición puntual, posiblemente asociado a fenómenos recientes, emergentes o de corta duración en el ranking. Finalmente, el cluster 3 concentró la mayor cantidad de artistas y se caracterizó por baja presencia promedio, menor popularidad relativa y peor posición promedio en ranking. Por ello, fue interpretado como un grupo de artistas con baja presencia o menor posicionamiento local dentro del periodo analizado.

Estos perfiles deben entenderse como una segmentación exploratoria basada en señales digitales de Spotify Chile. No representan una predicción directa de convocatoria real, ya que el dataset no contiene información de venta de entradas ni asistencia a eventos.

	cantidad_artistas	apariciones_chile	canciones_unicas_chile	rank_promedio_chile	popularidad_promedio	movimiento_diario_promedio	movimi
cluster							
0	165	132.72	1.41	24.63	76.62	0.59	
1	53	4.43	1.60	23.27	55.37	17.39	
2	3	1370.67	15.00	23.47	84.81	0.35	
3	187	15.28	1.16	42.56	60.67	2.04	

Figura 21. Caracterización promedio de los clusters obtenidos mediante K-Means.




Figura 22. Visualización de clusters de artistas mediante PCA y K-Means.

3.7. Implementación del modelo supervisado MLP.

Luego de obtener los clusters mediante K-Means, se implementó un modelo supervisado de clasificación binaria utilizando una red neuronal de tipo Perceptrón Multicapa. Esta etapa tuvo como objetivo aprender a clasificar artistas según una etiqueta técnica derivada de los perfiles encontrados previamente.

La variable objetivo se construyó a partir de los cuatro clusters obtenidos en la etapa no supervisada. Los clusters 0 y 2 fueron agrupados como clase positiva, al representar artistas con presencia sostenida o alto desempeño local en Spotify Chile. En cambio, los clusters 1 y 3 fueron agrupados como clase negativa, al representar artistas de aparición puntual o menor posicionamiento local.

Como resultado de esta reagrupación, se obtuvo una distribución de 168 artistas en la clase positiva y 240 artistas en la clase negativa. Esta etiqueta no representa ventas reales de

entradas ni asistencia a eventos, sino una clasificación técnica basada en señales digitales disponibles en el dataset.

```
alto_potencial
0    240
1    168
Name: count, dtype: int64
```

Figura 23. Construcción de la etiqueta técnica binaria a partir de los clusters.

Para el entrenamiento del modelo, se definieron como variables predictoras las 8 métricas utilizadas previamente en el modelamiento: apariciones en Chile, canciones únicas, ranking promedio, popularidad promedio, movimiento diario promedio, movimiento semanal promedio, permanencia en días y puntaje de posición local.

El conjunto de datos fue dividido en tres subconjuntos: entrenamiento, validación y prueba, utilizando una proporción 60/20/20. El conjunto de entrenamiento quedó compuesto por 244 registros, el conjunto de validación por 82 registros y el conjunto de prueba por 82 registros. Esta división permitió entrenar el modelo, ajustar su comportamiento durante la validación y reservar datos no observados para la evaluación final.

```
Train: (244, 8)
Val:   (82, 8)
Test:  (82, 8)
```

Figura 24. Partición del conjunto de datos en entrenamiento, validación y prueba.

La arquitectura del modelo se definió como una red neuronal secuencial compuesta por una capa de entrada para las 8 variables predictoras, una primera capa oculta densa de 16 neuronas con activación ReLU, una capa Dropout con tasa de 0,3 para reducir el riesgo de sobreajuste, una segunda capa oculta densa de 8 neuronas con activación ReLU y una capa de salida con una neurona y activación sigmoide para clasificación binaria.

El modelo fue compilado con el optimizador Adam, una tasa de aprendizaje de 0,001, función de pérdida `binary_crossentropy` y métricas de evaluación `accuracy` y `AUC`. Esta configuración fue adecuada para un problema de clasificación binaria y permitió monitorear tanto la exactitud del modelo como su capacidad de discriminación entre ambas clases.

Model: "sequential"

Layer (type)	Output Shape	Param #
Capa_Ocultas_1 (Dense)	(None, 16)	144
Dropout_1 (Dropout)	(None, 16)	0
Capa_Ocultas_2 (Dense)	(None, 8)	136
Capa_Salida (Dense)	(None, 1)	9

Total params: 289 (1.13 KB)

Trainable params: 289 (1.13 KB)

Non-trainable params: 0 (0.00 B)

Figura 25. Arquitectura de la red neuronal Perceptr3n Multicapa.

3.8. Comparaci3n de estrategias de balanceo

Debido a que la etiqueta t3cnica binaria present3 una distribuci3n desigual entre clases, se compararon distintas estrategias de balanceo para evaluar su efecto sobre el rendimiento del modelo MLP. En el conjunto de entrenamiento, la clase 0 qued3 compuesta por 144 registros y la clase 1 por 100 registros, por lo que se probaron cuatro escenarios: modelo sin balanceo, modelo con ponderaci3n de clases, modelo con sobremuestreo de la clase minoritaria y modelo con submuestreo de la clase mayoritaria.

Los resultados muestran que el modelo con sobremuestreo obtuvo el menor valor de p3rdida en validaci3n y el mayor AUC, con un valor de 0,9945. Adem3s, mantuvo una exactitud de 0,9634, una precisi3n de 0,9429, un recall de 0,9706 y un F1-score de 0,9565.

Aunque el submuestreo alcanz3 un recall de 1,0000 y un F1-score levemente superior, esta estrategia elimina registros de la clase mayoritaria, lo que puede reducir informaci3n 3til del entrenamiento. Por esta raz3n, se seleccion3 el modelo con sobremuestreo como modelo final, ya que logr3 un buen equilibrio entre desempe1o, estabilidad y conservaci3n de informaci3n.

	Escenario	Loss_validacion	Accuracy_validacion	Precision_validacion	Recall_validacion	F1_validacion	AUC_validacion
0	Submuestreo	0.3293	0.9634	0.9189	1.0000	0.9577	0.9939
1	Sobremuestreo	0.2903	0.9634	0.9429	0.9706	0.9565	0.9945
2	Sin balanceo	0.3004	0.9512	0.9167	0.9706	0.9429	0.9939
3	Ponderaci3n de clases	0.2999	0.9512	0.9167	0.9706	0.9429	0.9939

Figura 26. Comparaci3n de estrategias de balanceo en el conjunto de validaci3n.

3.9. Evaluaci3n final del modelo seleccionado

Luego de comparar las estrategias de balanceo, se seleccion3 como modelo final el MLP entrenado con sobremuestreo de la clase minoritaria. Esta decisi3n se bas3 en su rendimiento en validaci3n, especialmente por presentar el menor valor de p3rdida y el mayor AUC entre

los modelos comparados. En el notebook final, el modelo seleccionado se definió explícitamente como `modelo_final = modelo_sobremuestreo`.

La evaluación final se realizó sobre el conjunto de prueba, compuesto por 82 registros que no fueron utilizados durante el entrenamiento ni durante la validación. En este conjunto, el modelo obtuvo una exactitud de 0,9878, precisión de 1,0000, recall de 0,9706, F1-score de 0,9851 y AUC de 1,0000. Estos resultados indican que la red neuronal logró clasificar correctamente la mayoría de los artistas según la etiqueta técnica definida a partir de los perfiles de desempeño local en Spotify Chile.

```
Evaluación final en conjunto de prueba - modelo seleccionado con sobremuestreo
Accuracy: 0.9878
Precision: 1.0000
Recall: 0.9706
F1-score: 0.9851
AUC: 1.0000
```

Figura 27. Evaluación final del modelo seleccionado en el conjunto de prueba.

Es importante interpretar estos resultados con cautela. La variable objetivo no corresponde a ventas reales de entradas, asistencia a eventos ni convocatoria medida directamente, sino a una etiqueta técnica construida a partir de clusters generados con variables de Spotify Chile. Por lo tanto, el modelo no valida la convocatoria real de los artistas, sino que demuestra que la arquitectura MLP logra aprender patrones asociados a la señal digital local observada en el dataset.

3.10. Visualización de la matriz de confusión

Para complementar la evaluación final, se construyó una matriz de confusión sobre el conjunto de prueba. Esta visualización permite observar cuántos artistas fueron clasificados correctamente en cada clase y cuántos casos fueron clasificados de forma incorrecta.

La matriz de confusión muestra que el modelo clasificó correctamente 48 casos de la clase 0 y 33 casos de la clase 1. Además, no se observaron falsos positivos, mientras que solo un artista perteneciente a la clase de mayor señal digital local fue clasificado como clase 0. Esto explica que la precisión sea 1,0000 y que el recall sea 0,9706.

```
Matriz de confusión:
[[48  0]
 [ 1 33]]
```

Figura 28. Matriz de confusión del modelo seleccionado en el conjunto de prueba.

Estos resultados refuerzan que el modelo logró reproducir de manera consistente la etiqueta técnica derivada de los clusters. Sin embargo, al igual que en la evaluación global, esta matriz no debe interpretarse como una prueba de convocatoria real, sino como una evaluación del desempeño del modelo frente a la clasificación técnica construida a partir de señales digitales de Spotify Chile.

3.11. Explicabilidad del modelo con SHAP

Para interpretar el comportamiento del modelo supervisado seleccionado, se aplicó SHAP (Lundberg y Lee, 2017) como herramienta de explicabilidad. Esta técnica permite estimar la contribución de cada variable en las predicciones del modelo, ayudando a comprender qué factores tuvieron mayor influencia en la clasificación de los artistas.

El análisis mostró que las variables con mayor importancia promedio absoluta fueron `rank_promedio_chile` y `puntaje_posicion_chile`, con valores de 0,097968 y 0,097160, respectivamente. Esto indica que el modelo asignó alta relevancia a variables relacionadas con la posición alcanzada por los artistas dentro del ranking chileno de Spotify.

En tercer lugar apareció `movimiento_semanal_promedio`, con una importancia SHAP de 0,057790, seguida por `permanencia_dias`, con 0,047949, y `apariciones_chile`, con 0,040521. Esto sugiere que el comportamiento temporal, la permanencia en rankings y la frecuencia de aparición también aportan a la clasificación de mayor o menor señal digital local.

Tabla 4. Importancia promedio absoluta de variables según SHAP.

Variable	Importancia SHAP promedio absoluta
<code>rank_promedio_chile</code>	0,097968
<code>puntaje_posicion_chile</code>	0,097160
<code>movimiento_semanal_promedio</code>	0,057790
<code>permanencia_dias</code>	0,047949
<code>apariciones_chile</code>	0,040521
<code>popularidad_promedio</code>	0,016210
<code>movimiento_diario_promedio</code>	0,011828
<code>canciones_unicas_chile</code>	0,010870

Además, se generó un gráfico resumen de SHAP para observar la distribución de los efectos de cada variable sobre las predicciones. Este gráfico permite analizar no solo qué variables son importantes, sino también cómo sus valores altos o bajos se relacionan con el aumento o disminución de la probabilidad de pertenecer a la clase de mayor señal digital local.




Figura 29. Gráfico resumen SHAP del modelo seleccionado.

3.12. Revisión de casos particulares del conjunto de prueba

Además de las métricas globales, se revisaron casos particulares del conjunto de prueba para observar cómo el modelo clasificó artistas específicos. Para esto, se construyó una tabla con el artista, perfil de cluster, clase real, clase predicha, probabilidad estimada de mayor señal digital local y variables principales de desempeño.

Entre los casos con mayor probabilidad de pertenecer a la clase de mayor señal digital local aparecen artistas o combinaciones como Myke Towers, Katteyes/Kidd Voodoo/Swift 047, King Savage/Jairo Vera/Bayron Fire, Lucky Brown/Mateo on the Beatz, Bad Bunny y otros casos con alta presencia o buen posicionamiento en Spotify Chile. En varios de estos registros, la probabilidad estimada fue cercana o igual a 1,0.

Casos con mayor probabilidad de alta señal digital local en Spotify:

	artists	perfil_cluster	alto_potencial	clase_predicha	clasificacion_correcta	probabilidad_alta_senal_spotify	apariciones_chile	rank_promedio_chile	permai
287	Myke Towers	Presencia sostenida en rankings chilenos	1	1	True	1.0	340	25.297059	
191	Katteyes, Kidd Voodoo, Swift 047	Presencia sostenida en rankings chilenos	1	1	True	1.0	60	5.700000	
219	King Savage, Jairo Vera, Bayron Fire	Presencia sostenida en rankings chilenos	1	1	True	1.0	187	11.775401	
204	Kidd Voodoo, DrefQuila, Young Cister, Easykid,...	Presencia sostenida en rankings chilenos	1	1	True	1.0	113	7.575221	
256	Lucky Brown, Mateo on the Beatz	Presencia sostenida en rankings chilenos	1	1	True	1.0	357	19.529412	
22	Bad Bunny	Artistas consolidados de alto desempeño local	1	1	True	1.0	1233	18.789943	
98	FloyyMenor, Gata M...	Presencia sostenida en rankings chilenos	1	1	True	1.0	392	17.867347	

Figura 30. Casos del conjunto de prueba con mayor probabilidad de alta señal digital local.

También se revisaron los casos con menor probabilidad de pertenecer a la clase positiva. En este grupo aparecen artistas o combinaciones con baja presencia, menor permanencia o peor posicionamiento promedio en el ranking chileno. La menor probabilidad observada fue cercana a 0,2909, lo que muestra que el modelo no necesariamente entrega probabilidades extremas de 0, sino valores asociados al patrón aprendido.

Casos con menor probabilidad de alta señal digital local en Spotify:

	artists	perfil_cluster	alto_potencial	clase_predicha	clasificacion_correcta	probabilidad_alta_senal_spotify	apariciones_chile	rank_promedio_chile	perm
137	Jairo Vera, Gino Mella, Ak4:20, Bayriton, Abra...	Baja presencia o menor posicionamiento local	0	0	True	0.2909	6	39.500000	
176	Juliano Sosa, King Savage, Ak4:20, Jairo Vera	Baja presencia o menor posicionamiento local	0	0	True	0.2909	1	43.000000	
44	Blessd, Anuel AA	Aparición puntual o comportamiento emergente	0	0	True	0.2909	6	20.500000	
277	Mora	Baja presencia o menor posicionamiento local	0	0	True	0.2909	8	39.250000	
20	BRUNO MATEUS	Aparición puntual o comportamiento emergente	0	0	True	0.2909	4	23.750000	
297	Nickoog Clk, Gittobatz	Baja presencia o menor posicionamiento local	0	0	True	0.2909	97	40.896907	
212	Kidd Voodoo,	Baja presencia o menor posicionamiento	0	0	True	0.2909	5	41.800000	

Figura 31. Casos del conjunto de prueba con menor probabilidad de alta señal digital local.

Este análisis de casos particulares permite complementar la evaluación cuantitativa del modelo y facilita la interpretación de los resultados. Sin embargo, al igual que en las secciones anteriores, estas probabilidades no representan convocatoria real ni ventas esperadas, sino una estimación del modelo respecto de la etiqueta técnica construida a partir de señales digitales de Spotify Chile.

3.13. Diseño conceptual de frontend y backend

Junto con el desarrollo del modelo, se propuso un diseño conceptual de frontend y backend para representar cómo podría funcionar el sistema en un entorno de uso real. Esta propuesta no corresponde a una aplicación implementada completamente, sino a un mockup funcional a nivel conceptual, orientado a mostrar cómo se presentarían los resultados a usuarios no técnicos.

El backend estaría encargado de cargar el dataset, filtrar los registros correspondientes a Chile, limpiar los datos, construir la base agregada por artista, calcular las variables de desempeño, aplicar PCA y K-Means, entrenar el modelo MLP, evaluar métricas y generar explicaciones mediante SHAP. Además, sería responsable de entregar los resultados al frontend mediante tablas, gráficos y rankings interpretables.




Figura 32a. Diseño conceptual del backend del sistema.



Figura 32b. Diseño conceptual del backend del sistema.

El frontend estaría orientado a productoras, equipos de marketing u organizadores de eventos. Por ello, debería mostrar una interfaz clara con filtros por artista, país, periodo, cluster y nivel de señal digital local. También debería incluir métricas principales, visualizaciones de desempeño, explicación de variables influyentes y una vista individual por artista.




Figura 33a. Mockup conceptual del frontend del sistema.




Figura 33b. Mockup conceptual del frontend del sistema.




Figura 33c. Mockup conceptual del frontend del sistema.




Figura 33d. Mockup conceptual del frontend del sistema.

Este diseño permite vincular los resultados técnicos del modelo con una posible herramienta de apoyo a la decisión. De esta manera, el proyecto no solo desarrolla un modelo de aprendizaje automático, sino que también plantea cómo sus resultados podrían ser comunicados de forma comprensible y útil.

3.14. Limitaciones del modelo y mejoras futuras

El modelo desarrollado presenta resultados favorables en términos de clasificación técnica, pero tiene limitaciones importantes. La principal limitación es que el dataset utilizado contiene rankings diarios de Spotify y no incluye datos reales de venta de entradas, asistencia a eventos, precios, recintos, ciudades, campañas publicitarias ni comportamiento de compra. Por lo tanto, el sistema no puede afirmar que un artista llenará un evento ni predecir convocatoria real.

Otra limitación es que la columna artists puede contener colaboraciones o múltiples artistas en una misma canción. En este proyecto se mantuvieron esas combinaciones tal como aparecen en Spotify, pero en futuras versiones sería conveniente separar o normalizar artistas individuales para evitar duplicidades o interpretaciones ambiguas.

También se debe considerar que la etiqueta usada por el modelo MLP fue construida a partir de clusters, por lo que corresponde a una etiqueta técnica interna. Esto significa que el modelo aprende a reproducir patrones derivados de Spotify Chile, pero no valida externamente la convocatoria musical.

Como mejoras futuras, se propone incorporar datos de otras plataformas, como YouTube, TikTok, Instagram, Apple Music o venta real de entradas. También sería útil incluir información de eventos realizados en Chile, capacidad de recintos, precios, ciudad, fecha, temporada y tipo de evento. Además, se podría comparar el desempeño del MLP con otros modelos, como Random Forest, Gradient Boosting o regresión logística, y aplicar validación temporal para evaluar si el modelo mantiene su rendimiento en periodos posteriores.

4. Resultados y análisis del modelo

El desarrollo del proyecto permitió construir un flujo completo de análisis y modelamiento a partir de rankings diarios de Spotify Chile. En primer lugar, se transformó el dataset original desde una unidad de análisis basada en canciones hacia una base agregada por artista o combinación de artistas. Posteriormente, se aplicaron técnicas no supervisadas para identificar perfiles de desempeño digital y, finalmente, se entrenó una red neuronal MLP para clasificar una etiqueta técnica derivada de dichos perfiles.

En la etapa no supervisada, PCA permitió reducir la dimensionalidad de las variables seleccionadas, conservando aproximadamente el 91% de la varianza acumulada con cuatro componentes principales. Esta reducción permitió aplicar K-Means sobre una representación más compacta de los datos. Con $k = 4$, los artistas fueron distribuidos en cuatro grupos: 165 artistas en el cluster 0, 53 en el cluster 1, 3 en el cluster 2 y 187 en el cluster 3.

La interpretación de estos clusters permitió distinguir perfiles de artistas con presencia sostenida, artistas consolidados de alto desempeño local, artistas de aparición puntual y artistas con menor posicionamiento dentro del ranking chileno. Estos perfiles fueron utilizados como base para construir una etiqueta técnica binaria, diferenciando artistas con mayor o menor señal digital local en Spotify Chile.

Luego, se implementó una red neuronal tipo Perceptrón Multicapa para clasificar esta etiqueta técnica. Tras comparar cuatro estrategias de balanceo, el modelo con sobremuestreo fue seleccionado como modelo final, ya que obtuvo el menor valor de pérdida en validación y el mayor AUC. En la evaluación final sobre el conjunto de prueba, el modelo alcanzó los siguientes resultados:

Tabla 5. Métricas finales del modelo seleccionado en el conjunto de prueba.

Métrica	Resultado
Accuracy	0,9878
Precision	1,0000
Recall	0,9706
F1-score	0,9851
AUC	1,0000

Estos resultados muestran que el modelo clasificó correctamente la mayoría de los casos del conjunto de prueba. La matriz de confusión indicó 48 verdaderos negativos, 33 verdaderos positivos, 0 falsos positivos y 1 falso negativo. Esto significa que el modelo no clasificó erróneamente como alta señal digital local a ningún artista de la clase negativa, aunque sí dejó un caso positivo clasificado como negativo.

La explicabilidad mediante SHAP permitió identificar qué variables influyeron más en las predicciones del modelo. Las variables más relevantes fueron `rank_promedio_chile` y `puntaje_posicion_chile`, seguidas por `movimiento_semanal_promedio`, `permanencia_dias` y `apariciones_chile`. Esto indica que el modelo dio mayor importancia a señales relacionadas con la posición alcanzada, el comportamiento temporal y la permanencia de los artistas en rankings de Spotify Chile.

Finalmente, la revisión de casos particulares mostró que artistas o combinaciones con alta presencia, mejor posicionamiento o mayor permanencia tendieron a obtener probabilidades más altas de pertenecer a la clase de mayor señal digital local. En cambio, artistas con menor presencia, baja permanencia o peor posicionamiento promedio tendieron a obtener

probabilidades más bajas. Este análisis permitió complementar las métricas globales con una interpretación más concreta de las predicciones.

A pesar del buen desempeño obtenido, los resultados deben interpretarse con cautela. La variable objetivo utilizada por el modelo no corresponde a ventas reales de entradas, asistencia a eventos ni convocatoria medida directamente. Se trata de una etiqueta técnica construida a partir de clusters y variables de Spotify Chile. Por lo tanto, el modelo no predice convocatoria real, sino que clasifica artistas según patrones de señal digital local observados en el dataset.

5. Repositorio GitHub y reproducibilidad

El proyecto fue desarrollado en un entorno de trabajo basado en Python y Jupyter Notebook, utilizando bibliotecas especializadas para análisis de datos, modelamiento, evaluación y explicabilidad. El código fue organizado en un repositorio GitHub con el objetivo de facilitar la trazabilidad del desarrollo, la revisión del proceso metodológico y la reproducción de los resultados obtenidos.

El repositorio contiene el notebook principal del proyecto, donde se documentan las etapas de carga de datos, limpieza, filtrado del subconjunto correspondiente a Chile, análisis exploratorio, construcción de la base agregada por artista, reducción de dimensionalidad mediante PCA, segmentación con K-Means, entrenamiento del modelo MLP, comparación de estrategias de balanceo, evaluación final y análisis de explicabilidad mediante SHAP.

Además, se incorporó un archivo requirements.txt con las principales librerías necesarias para ejecutar el proyecto, entre ellas pandas, numpy, scikit-learn, matplotlib, tensorflow, shap, tqdm e ipywidgets. Esto permite que el entorno de ejecución pueda ser replicado por otros usuarios o evaluadores.

El archivo README del repositorio resume el objetivo del proyecto, el dataset utilizado, la metodología aplicada, las principales técnicas implementadas y las instrucciones básicas para ejecutar el notebook. De esta forma, el repositorio funciona como respaldo técnico del informe y permite verificar el flujo completo de trabajo desarrollado.

Repositorio GitHub del proyecto:

<https://github.com/omarsanhuezaperiodista-ai/omarunab>

6. Conclusiones

El proyecto permitió desarrollar un sistema de análisis y clasificación de artistas con base en señales digitales obtenidas desde rankings diarios de Spotify Chile. A partir del dataset original, se construyó una base agregada por artista o combinación de artistas, lo que permitió transformar registros diarios de canciones en variables útiles para el análisis de desempeño musical local.

El análisis exploratorio permitió identificar patrones relevantes en torno a apariciones en rankings, permanencia, popularidad, posición promedio y movimiento diario o semanal. Posteriormente, la aplicación de PCA permitió reducir la dimensionalidad del conjunto de variables, conservando aproximadamente el 91% de la información acumulada con cuatro componentes principales.

Mediante K-Means se identificaron cuatro perfiles de artistas, diferenciando entre artistas con presencia sostenida, artistas consolidados de alto desempeño local, artistas de aparición puntual y artistas con menor posicionamiento dentro del ranking chileno. Estos perfiles permitieron construir una etiqueta técnica binaria, utilizada posteriormente para entrenar un modelo supervisado.

La red neuronal MLP obtuvo un alto desempeño en el conjunto de prueba, especialmente al utilizar sobremuestreo como estrategia de balanceo. El modelo final alcanzó una exactitud de 0,9878, precisión de 1,0000, recall de 0,9706, F1-score de 0,9851 y AUC de 1,0000. Estos resultados muestran que el modelo logró aprender de forma consistente los patrones asociados a la etiqueta técnica construida.

El análisis con SHAP permitió interpretar el comportamiento del modelo, mostrando que las variables más influyentes fueron el ranking promedio en Chile, el puntaje de posición, el movimiento semanal, la permanencia y la cantidad de apariciones. Esto refuerza la coherencia del modelo, ya que las variables más importantes están directamente relacionadas con señales observables de desempeño musical en Spotify Chile.

Sin embargo, es fundamental señalar que el modelo no predice convocatoria real ni ventas de entradas. La clasificación obtenida representa una estimación de mayor o menor señal digital local dentro de Spotify Chile, construida a partir de los datos disponibles. Por ello, el sistema debe entenderse como una herramienta de apoyo exploratorio para la toma de decisiones, no como una predicción definitiva de éxito comercial o asistencia a eventos.

Como trabajo futuro, se recomienda incorporar datos de otras plataformas digitales, redes sociales, ventas de tickets, características de eventos, ciudades, recintos y periodos temporales posteriores. Esto permitiría construir un sistema más robusto, capaz de relacionar señales digitales con indicadores reales de convocatoria musical en Chile.

Referencias

- Asaniczka. (s. f.). Top Spotify songs in 73 countries (daily updated) [Data set]. Kaggle. <https://www.kaggle.com/datasets/asaniczka/top-spotify-songs-in-73-countries-daily-updated>
- Cabansag, I. J., & Ntegeka, P. (2025). Prediction of Spotify chart success using audio and streaming features. arXiv. <https://doi.org/10.48550/arXiv.2508.11632>
- Hastie, T., Tibshirani, R., & Friedman, J. (2009). The elements of statistical learning: Data mining, inference, and prediction (2.^a ed.). Springer. <http://www.stat.ucla.edu/~ywu/research/documents/BOOKS/ElementsLearningII.pdf>
- Jiang, S. (2025). Predicting music popularity: A machine learning approach using Spotify data. En Proceedings of the 1st International Conference on Modern Logistics and Supply Chain Management (MLSCM 2024) (pp. 324–328). SCITEPRESS. <https://doi.org/10.5220/0013330000004558>
- Kingma, D. P., & Ba, J. (2014). Adam: A method for stochastic optimization. arXiv. <https://doi.org/10.48550/arXiv.1412.6980>
- Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. En I. Guyon et al. (Eds.), Advances in Neural Information Processing Systems 30 (pp. 4765–4774). Curran Associates.
- Saragih, H. S. (2023). Predicting song popularity based on Spotify's audio features: Insights from the Indonesian streaming users. Journal of Management Analytics, 10(4), 693–709. <https://doi.org/10.1080/23270012.2023.2239824>
- Schranz, C., Pilosov, M., & Beeking, M. (2025). GPU-Jupyter: A framework for reproducible deep learning research [Preprint]. ResearchGate. <https://doi.org/10.13140/RG.2.2.15549.99040>
- Scikit-learn developers. (s. f.). sklearn.cluster.KMeans. Scikit-learn. Recuperado el 27 de julio de 2026, de <https://scikit-learn.org/stable/modules/generated/sklearn.cluster.KMeans.html>
- Scikit-learn developers. (s. f.). sklearn.preprocessing.StandardScaler. Scikit-learn. Recuperado el 27 de julio de 2026, de <https://scikit-learn.org/stable/modules/generated/sklearn.preprocessing.StandardScaler.html>
- Sebastian Jung, N., & Mayer, F. (2024). Beyond beats: A recipe to song popularity? A machine learning approach. arXiv.
- Sudipa, I. G. I., Sugiartawan, P., & Wiguna, I. K. A. G. (2022). Modification weight criteria with webbed model for selection artist music festival using Analytical Hierarchy Process (AHP). IJCCS (Indonesian Journal of Computing and Cybernetics Systems), 16(1), 91–100. <https://doi.org/10.22146/ijccs.72434>

Terroso-Saenz, F., Soto, J., & Muñoz, A. (2023). Music mobility patterns: How songs propagate around the world through Spotify. *Pattern Recognition*, 143, 109807. <https://doi.org/10.1016/j.patcog.2023.109807>

Turnbull, D. R., McQuillan, S., Crabtree, V., Hunter, J., & Zhang, S. (2022). Exploring popularity bias in music recommendation models and commercial streaming services. *arXiv*. <https://doi.org/10.48550/arXiv.2208.09517>

Zhang, A., Lipton, Z. C., Li, M., & Smola, A. J. (2023). *Dive into deep learning*. Cambridge University Press. https://d2l.ai/chapter_multilayer-perceptrons/mlp.html